Proyecto final de Machine Learning

Descripción de requerimientos

1. Descripción general

El proyecto final tiene como objetivo que los estudiantes seleccionen un problema del mundo real y le apliquen Machine Learning de principio a fin, integrando los conocimientos vistos durante el curso. El trabajo debe cubrir el preprocesamiento de los datos y, como mínimo, uno de los paradigmas de aprendizaje estudiados, y debe llegar hasta el despliegue de un modelo que pueda ser usado por clientes reales.

Se espera que los estudiantes no solo entrenen un modelo, sino que demuestren y sustenten que este funciona bien sobre datos no vistos, es decir, que es generalizable, y que justifiquen cada una de las decisiones tomadas durante el desarrollo.

2. Conocimientos que se espera aplicar

Los estudiantes pueden apoyarse en cualquiera de los temas trabajados en el curso:

- **Aprendizaje supervisado:** preprocesamiento, kNN, árboles de decisión, Gradient Boosting, Random Forest, SVM y SVR, y explicabilidad con SHAP.
- **Aprendizaje no supervisado:** clustering jerárquico, DBSCAN, K-Medias y PCA.
- **Aprendizaje por refuerzo:** Q-Learning.

3. Requerimientos del proyecto

3.1 Selección del problema

El grupo debe elegir un problema real en el que la aplicación de Machine Learning tenga sentido. Debe describir el contexto, quiénes serían los usuarios o clientes, qué decisión o tarea apoyaría el modelo y de dónde provienen los datos.

3.2 Preprocesamiento de datos

Es obligatorio realizar y documentar el preprocesamiento de los datos (limpieza, tratamiento de valores faltantes y atípicos, codificación, escalado, entre otros, según corresponda al problema), justificando por qué cada paso es necesario.

3.3 Análisis exploratorio de datos (EDA)

Todo proyecto basado en aprendizaje supervisado o no supervisado debe incluir un EDA profundo, acompañado de la descripción de los insights encontrados y de cómo estos influyeron en las decisiones de preprocesamiento y modelado.

3.4 Paradigma y modelado

El proyecto debe aplicar al menos uno de los paradigmas vistos: aprendizaje supervisado, no supervisado o por refuerzo. Si el equipo lo desea, puede combinar más de uno cuando el problema lo justifique.

3.5 Metodología de entrenamiento y selección del modelo

Los estudiantes deben sustentar la metodología de entrenamiento utilizada, la selección del modelo y la elección de sus parámetros o hiperparámetros. Esto implica explicar qué alternativas consideraron, cómo las compararon y por qué la opción final es la más adecuada para su problema.

3.6 Generalización del modelo

El equipo debe garantizar y sustentar que el modelo funciona bien en datos no vistos. Debe explicar la estrategia con la que evaluó la generalización y evidenciar que el desempeño reportado no es producto de sobreajuste ni de fuga de información.

3.7 Métricas de desempeño

Las métricas de desempeño deben estar justificadas: los estudiantes deben explicar por qué las métricas elegidas son las apropiadas para su problema y qué significan en términos del uso real del modelo.

3.8 Despliegue e interfaz

El modelo debe desplegarse para el uso de los clientes. Para ello, los estudiantes deben preparar una interfaz que facilite la interacción con el modelo, de modo que una persona sin conocimientos técnicos pueda usarlo.

3.9 Estrategia de reajuste del modelo

El equipo debe diseñar una estrategia para un eventual reajuste del modelo cuando este lleve un buen tiempo en producción. Por ejemplo, debe contemplar cómo se detectaría que el desempeño se ha degradado o que los datos han cambiado, con qué criterio y frecuencia se decidiría reentrenar, y cómo se validaría y pondría en producción la nueva versión.

4. Entregables

Cada equipo debe entregar los siguientes elementos:

- **Video de demostración:** de 2 minutos de duración, mostrando el funcionamiento del modelo desplegado y su interfaz.
- **Enlace al repositorio del proyecto:** el repositorio es el medio para la entrega de la documentación y la justificación de las decisiones tomadas.
- **Notebook model_development.ipynb:** debe contener el paso a paso del entrenamiento del modelo y la justificación de las decisiones tomadas. En los proyectos de aprendizaje supervisado y no supervisado debe incluir el EDA profundo y la descripción de los insights.

5. Evaluación

La calificación final se compone de dos partes iguales:

- **Entrega oportuna de los entregables:** 50 % de la nota.
- **Presentación final:** 50 % de la nota.

En la presentación final el equipo sustentará el problema, la metodología, la selección del modelo y de sus parámetros, la generalización, las métricas, el despliegue y la estrategia de reajuste.